Tugas 1 — Audit Data dan Exploratory Data Analysis

Salman Rachmadi

NIM 203012420009

Visualisasi Data Lanjut

Dataset: 203012420009_layanan.csv (4.100 baris, 12 kolom)

Bagian A — Audit kualitas data

Dataset `203012420009_layanan.csv` masih layak digunakan untuk menggambarkan kondisi layanan dan penjualan, asalkan dilakukan *cleaning* lebih dulu. Ke-9 masalah yang ditemukan terlihat jelas dari ringkasan dan audit data, sehingga dapat di-filter sebelum data divisualisasikan: hanya 104 baris (2,5%) yang dibuang.

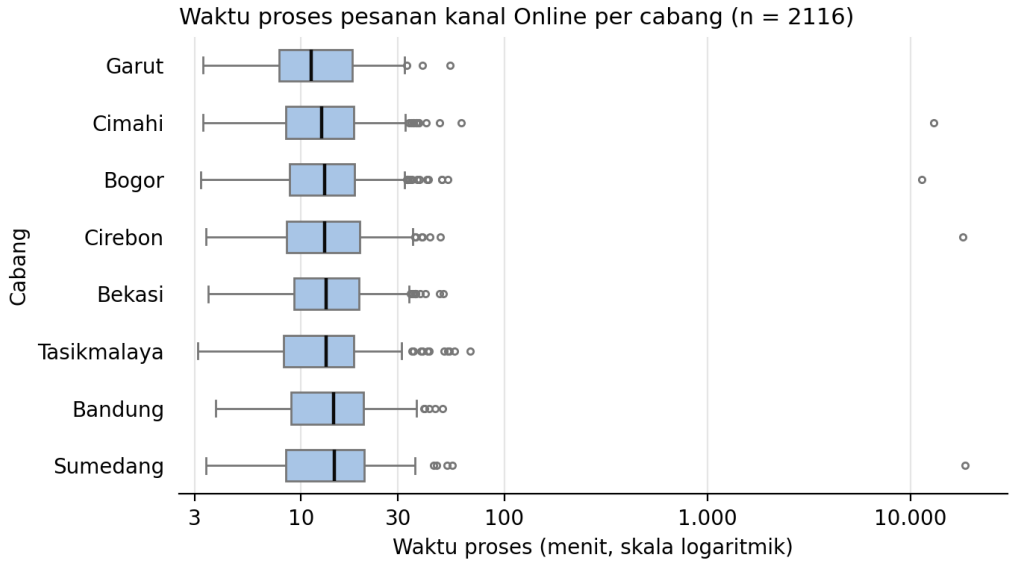
Persentase dihitung terhadap 4.100 baris mentah. Setelah pembersihan, data berisi 3.996 baris dengan id_transaksi unik.

No	Kolom terdampak	Jenis masalah	Bukti	Dampak	Keputusan dan alasan
1	kanal	Tidak konsisten	11 penulisan untuk dua kanal: beda huruf besar-kecil, spasi di depan, tanda hubung, serta Daring/Luring	260 baris (6,3%)	Diseragamkan menjadi Online dan Offline. Agar jenis kanal lebih mudah di kategorikan
2	tanggal	Tidak konsisten	Dua format: yyyy-mm-dd dan dd/mm/yyyy (bagian pertama mencapai 31)	376 baris (9,2%)	Diubah ke satu format bertipe tanggal. Akan memudahkan pengurutan transaksi bedasarakan tanggal
3	Semua kolom	Duplikat persis	65 baris identik dengan baris lain; 7 di antaranya baru terlihat setelah tanggal seragam	65 baris (1,6%)	Dihapus, satu salinan dipertahankan, setelah kanal dan tanggal seragam. Agar tidak mempengaruhi median ataupun mean dari data yang ada
4	id_transaksi	Duplikat, isi berbeda	39 id muncul dua kali dengan waktu_proses_menit berbeda 0,1–4,7 menit; satu pasang juga berbeda tahun (2025 dan 2027)	39 baris dibuang (1,0%)	Baris bertanggal valid (paling lambat Oktober 2026) diutamakan, selebihnya baris pertama.
5	jumlah_unit	Mustahil	Bernilai 0 padahal total_transaksi lebih dari 0	12 baris (0,3%)	Diisi dari total_transaksi / (harga_satuan × (1 − diskon)); hasilnya bulat, 1–5.
6	waktu_proses_menit	Mustahil	Nilai negatif, minimum −22,8 menit	15 baris (0,4%)	Diubah menjadi nilai hilang, baris dipertahankan. Dengan asumsi tidak mungkin ada layanan yang bersifat negatif
7	rating_pelanggan	Nilai hilang tersamar	Nilai 999 pada skala 1–5; rata-rata kolom menjadi 42,9	157 baris (3,8%)	Diubah menjadi nilai hilang, baris dipertahankan.
8	rating_pelanggan	Nilai	Sel kosong	105 baris	Dibiarkan kosong.

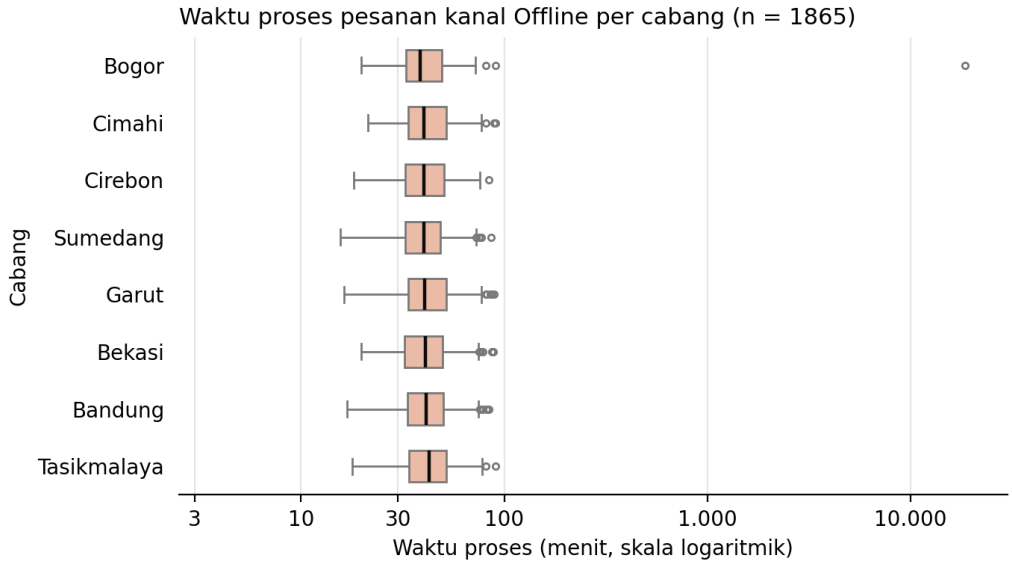
		hilang		(2,6%)	Karena asumsi data tersebut nantinya tidak digunakan sebagai pengambilan mean ataupun median
9	harga_satuan, total_transaksi	Satuan berbeda	Cabang Cirebon: median harga_satuan 84,2, cabang lain 69.400–85.200; per kategori produk selisihnya 990–1.011 kali. Semua harga Cirebon di bawah 2.243, semua harga cabang lain di atas 21.800	538 baris (13,1%)	Dikonversi ke rupiah (dikali 1.000). Untuk menyeragamkan total transaksi

Bagian B — Temuan hubungan antar variabel

B1. Sebaran waktu proses pesanan



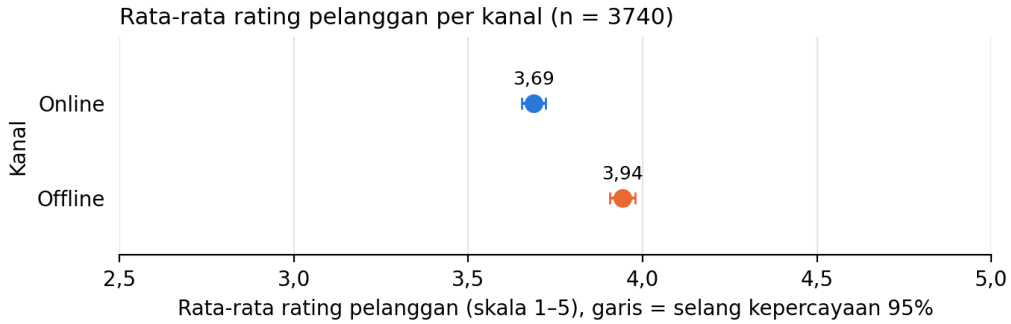
Gambar 1. Sebaran waktu proses pesanan kanal Online per cabang (box plot, n = 2.116, sumbu logaritmik). Sebagian besar pesanan (93,9%) selesai dalam 3 sampai 30 menit, dengan median yang hampir sama di semua cabang, yaitu 11,2 sampai 14,6 menit.



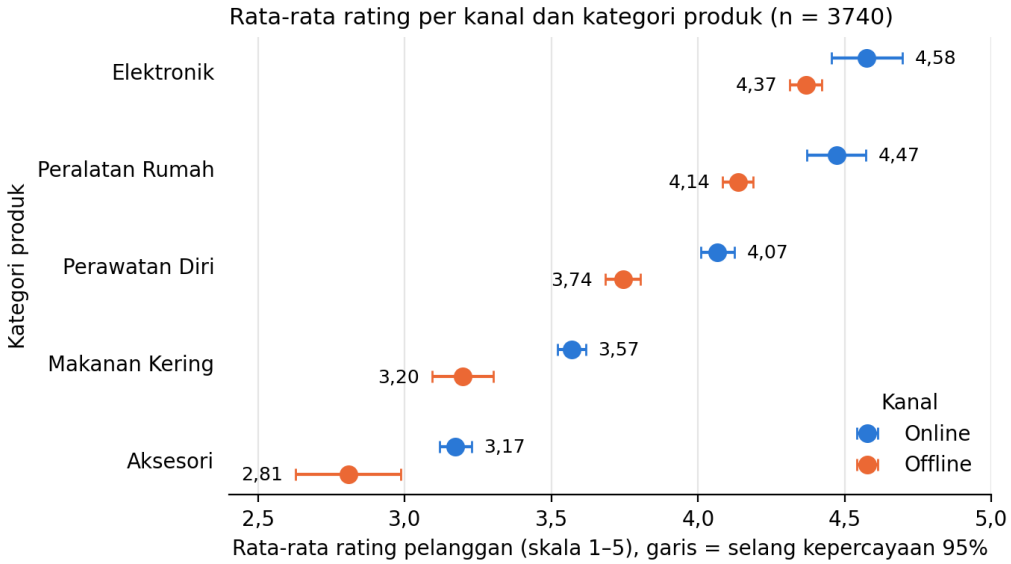
Gambar 2. Sebaran waktu proses pesanan kanal Offline per cabang (box plot, n = 1.865, sumbu logaritmik). Sebagian besar pesanan (96,1%) selesai dalam 15 sampai 70 menit, dengan median yang hampir sama di semua cabang, yaitu 38,5 sampai 42,7 menit.

Gambar 1 dan Gambar 2 menunjukkan sebaran waktu proses pesanan (menit) per cabang dalam bentuk box plot, masing-masing untuk kanal Online (2.116 transaksi) dan Offline (1.865 transaksi). Waktu proses berbeda jauh antar kanal: median Online 13,1 menit, sedangkan Offline 40,5 menit, sekitar tiga kali lebih lama. Separuh transaksi Online berada di antara 8,5 dan 18,8 menit, sedangkan Offline di antara 33,0 dan 50,5 menit. Di kedua kanal sebaran menceng ke kanan: tidak ada titik di bawah batas bawah, sedangkan titik di atas batas atas lebih banyak pada Online, yaitu 68 transaksi (3,2%), dibanding 30 transaksi (1,6%) pada Offline.

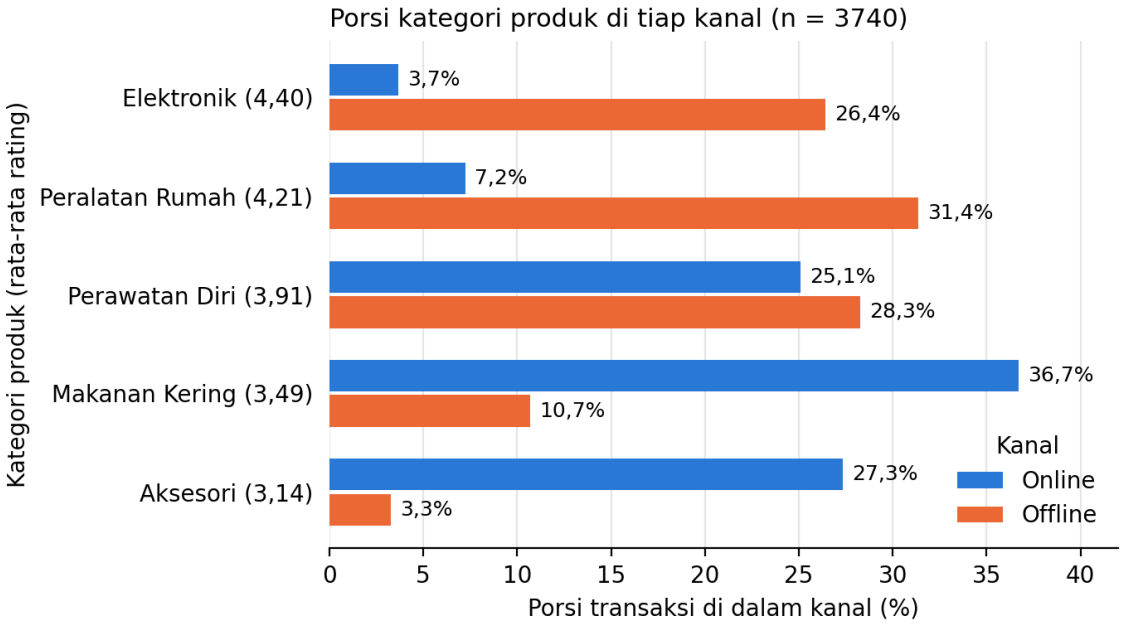
B2. Rating pelanggan per kanal dan kategori produk



Gambar 3. Rata-rata rating pelanggan per kanal (n = 3.740, garis = selang kepercayaan 95%). Secara keseluruhan, kanal Offline memiliki rating lebih tinggi daripada Online, yaitu 3,94 dibanding 3,69.



Gambar 4. Rata-rata rating pelanggan per kanal, dipilah per kategori produk (n = 3.740, garis = selang kepercayaan 95%). Setelah dipilah, kanal Offline justru memiliki rating lebih rendah daripada Online di kelima kategori, dengan selisih 0,21 sampai 0,37 poin.



Gambar 5. Online didominasi kategori berrating rendah, yaitu Makanan Kering dan Aksesori (64,0% transaksinya), sedangkan Offline didominasi kategori berrating tinggi, yaitu Elektronik dan Peralatan Rumah (57,8%).

Rata-rata rating (jumlah transaksi berrating dalam kurung):

	Semua kategori	Elektronik	Peralatan Rumah	Perawatan Diri	Makanan Kering	Aksesori
Online	3,69 (1.990)	4,58 (73)	4,47 (144)	4,07 (499)	3,57 (730)	3,17 (544)
Offline	3,94 (1.750)	4,37 (462)	4,14 (549)	3,74 (495)	3,20 (187)	2,81 (57)

Dari visualisasi Gambar 3, 4, dan 5 menunjukkan bahwa secara keseluruhan rata-rata rating kanal Offline (3,94) lebih tinggi daripada kanal Online (3,69) (Gambar 3). Namun, jika dipilah menurut kanal dan kategori produk, rata-rata rating kanal Online lebih tinggi daripada Offline di kelima kategori, dengan selisih 0,21 sampai 0,37 poin (Gambar 4). Hal ini terjadi karena penjualan kanal Online didominasi **Makanan Kering** dan **Aksesori** (64,0% transaksinya), dua kategori dengan rating terendah, sehingga rata-rata keseluruhan kanal Online menjadi lebih rendah daripada kanal Offline (Gambar 5).